

INSTITUTO POLITÉCNICO NACIONAL

UNIDAD PROFESIONAL INTERDISCIPLINARIA DE INGENIERÍA Y CIENCIAS SOCIALES Y ADMINISTRATIVAS.



Alumnos:

Pérez de Leon Hagopian Juan Carlos

Lozada Celis Ernesto

Gómez Vega Diego

Bustillos Segindo Jazmin

MATERIA:

ANALÍTICA DE DATOS

Secuencia:

6CM62

MAESTRO:

ENTZANA GARDUÑO YVENTZ

Trabajo:

Sistema analítico para la evaluación de la afluencia y movilidad en la red del metro de la Ciudad de México

Fecha de entrega: 22/09/2026

1. Definición del problema: **3**
2. Objetivo General: **3**
3. Objetivos Específicos: **3**
4. Diagrama Arquitectura **4**
5. Origen Datos **5**
Explicación General del Proyecto **6**
Definición y Caracterización de las Fuentes de Datos de Origen **6**
6. Modelado Semántico en IBM Cognos Analytics **8**
7. Explotación y Visualización (Dashboard Operativo) **9**

1. Definición del problema:

El Sistema de Transporte Colectivo “Metro” de la Ciudad de México es la columna vertebral de la movilidad urbana en la capital, transportando diariamente a millones de usuarios a través de sus 12 líneas y 195 estaciones. A pesar de la vasta cantidad de datos transaccionales y operativos generados continuamente por la operación de la red (conteo en torniquetes, despachos de trenes, bitácoras de incidencias y datos climáticos), la información disponible en el portal de Datos Abiertos de la CDMX y en los sistemas internos presenta serias limitaciones analíticas en su estado nativo:

- **Inexistencia de un modelo analítico multidimensional:** Las herramientas operativas actuales (OLTP) están optimizadas para la captura rápida de transacciones diarias, pero carecen de la estructura para realizar consultas analíticas complejas (OLAP), historización de datos y agregaciones temporales o geográficas interactivas.
- **Heterogeneidad y falta de estructura:** Los registros se encuentran dispersos en archivos planos desnormalizados (CSV y hojas de cálculo de Excel), caracterizados por redundancia de texto, variaciones ortográficas en nombres de estaciones/líneas y formatos de fecha inconsistentes.
- **Aislamiento transaccional (Silos de información):** Los datos operativos (frecuencias de trenes, averías, condiciones climáticas) operan desconectados de los registros de afluencia de usuarios, lo que impide realizar análisis correlacionales sobre las causas raíz del retraso en el servicio o la saturación en horas pico.

Esta desconexión de datos imposibilita a los analistas de transporte y directivos evaluar eficientemente el rendimiento de la red, identificar cuellos de botella en tiempo oportuno y tomar decisiones fundamentadas en datos para optimizar la dosificación de usuarios, la asignación del material rodante y la planeación de la movilidad urbana.

2. Objetivo General:

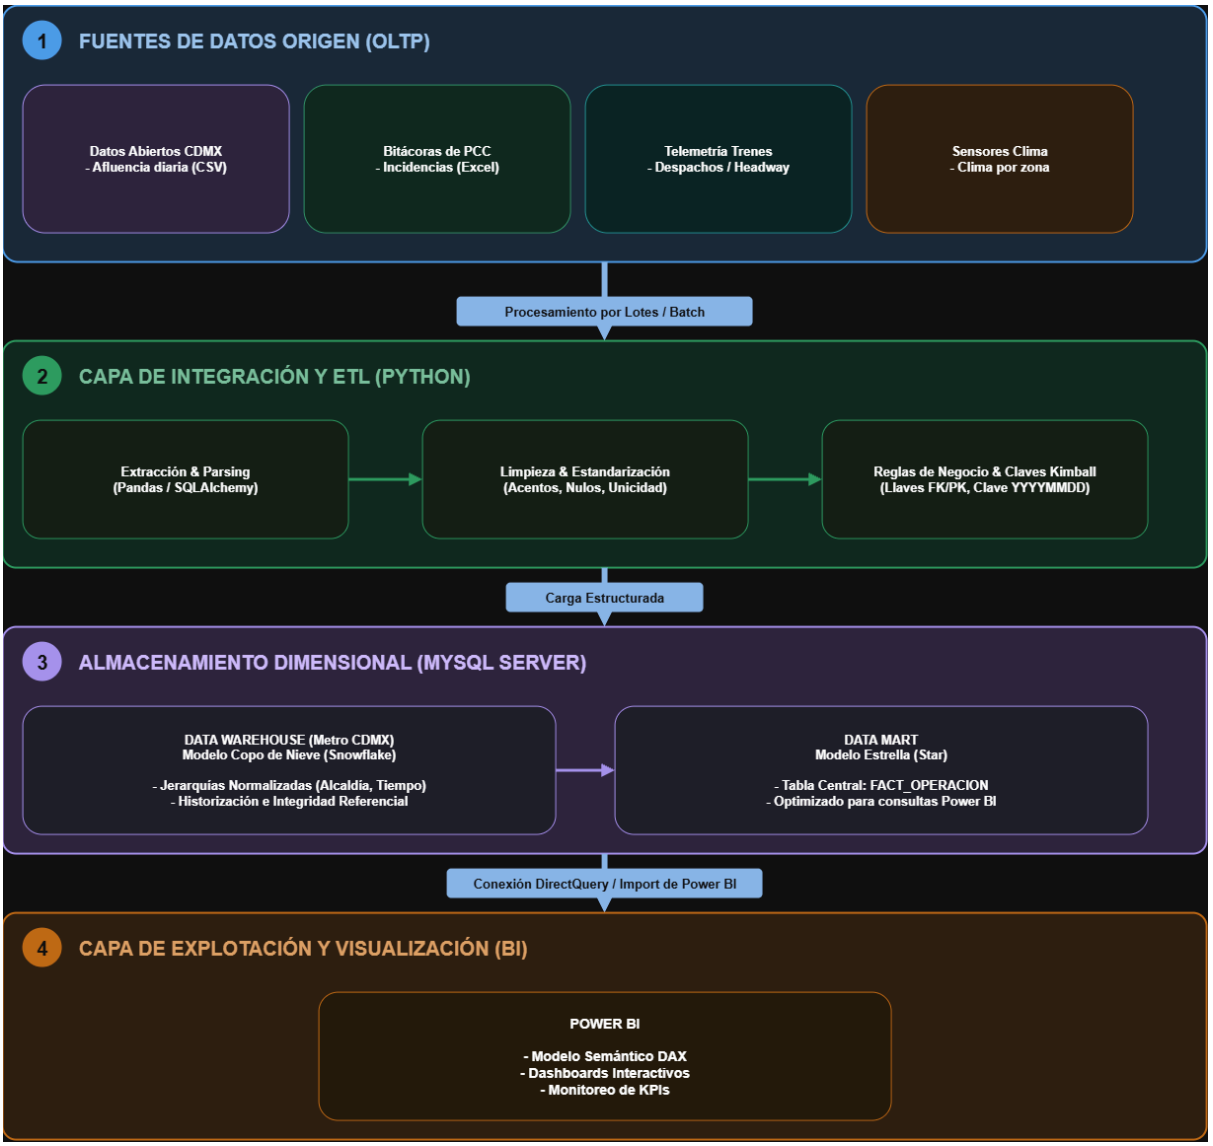
Diseñar e implementar una solución integral de inteligencia de negocios y analítica de datos para el procesamiento, almacenamiento dimensional (Data Warehouse y Data Mart) y explotación del histórico de afluencia del metro CDMX, permitiendo la evaluación de la movilidad urbana y sentando las bases para el análisis descriptivo y predictivo; logrando así optimizar la toma de decisiones sobre patrones de movilidad urbana.

3. Objetivos Específicos:

- **Ingesta y Procesamiento (ETL):** Desarrollar un pipeline automatizado en Python que extraiga, limpie y estandarice los datos abiertos del portal oficial de la CDMX, transformándolos a formatos de fecha Kimball (YYYYMMDD).
- **Modelado Dimensional Completo:** Estructurar la capa de almacenamiento en el Data Warehouse utilizando el modelo estrella (para consultas analíticas rápidas en Power BI) y el modelo copo de nieve (para garantizar la integridad referencial y la normalización de jerarquías geográficas y temporales).

- **Explotación y Visualización:** Diseñar tableros de control interactivos en la capa de Data Mart para monitorear métricas clave como afluencia_pasajeros, afluencia_hora_pico y porcentaje_ocupacion por estación y línea.
- **Análisis Predictivo:** Implementar modelos estadísticos sobre las series temporales del dataset para proyectar los días y horarios de mayor saturación en la red.

4. Diagrama Arquitectura



5. Origen Datos

Fuente de Datos	Tipo / Formato	Mecanismo de Ingesta	Descripción de Contenido	Campos Clave / Variables
Afluencia Diaria Metro (Datos Abiertos CDMX)	Estructurado (CSV)	Carga por lotes (Batch) vía Python	Registros diarios del volumen de pasajeros que ingresan por estación y línea.	fecha, linea, estacion, afluencia
Despacho de Convoys (Sistemas PCC)	Estructurado / Semi-estructurado (Excel/Logs)	Ingesta por pipeline ETL	Tiempos de salida de trenes, número de vagones, velocidad asignada e intervalo *headway*.	id_tren, id_linea, fecha_hora_salida, velocidad_kmh, intervalo_headway_seg
Bitácora de Incidencias Operativas	Semiestructurado (CSV / XLSX)	Extracción programada mediante Python (Generar reportes automáticos)	Reportes de fallas técnicas, tiempo de demora provocado y nivel de gravedad.	id_incidencia, tipo_incidencia, gravedad, tiempo_retraso_min
Registro Meteorológico por Zona	Estructurado (JSON / CSV)	Consolidación vía API / Archivo	Temperatura ambiental y presencia de lluvia que active el protocolo de marcha de seguridad.	id_sensor, fecha_hora, temperatura_c, clima_estado, aplica_marcha_seguridad

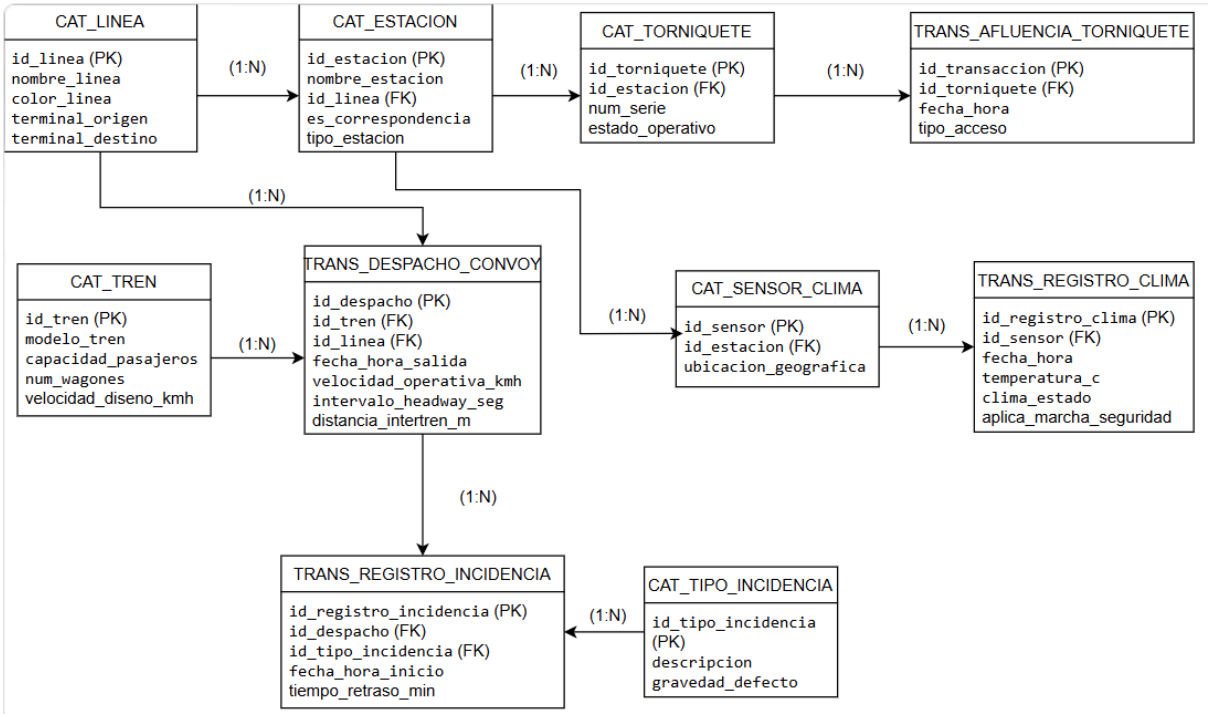
Explicación General del Proyecto

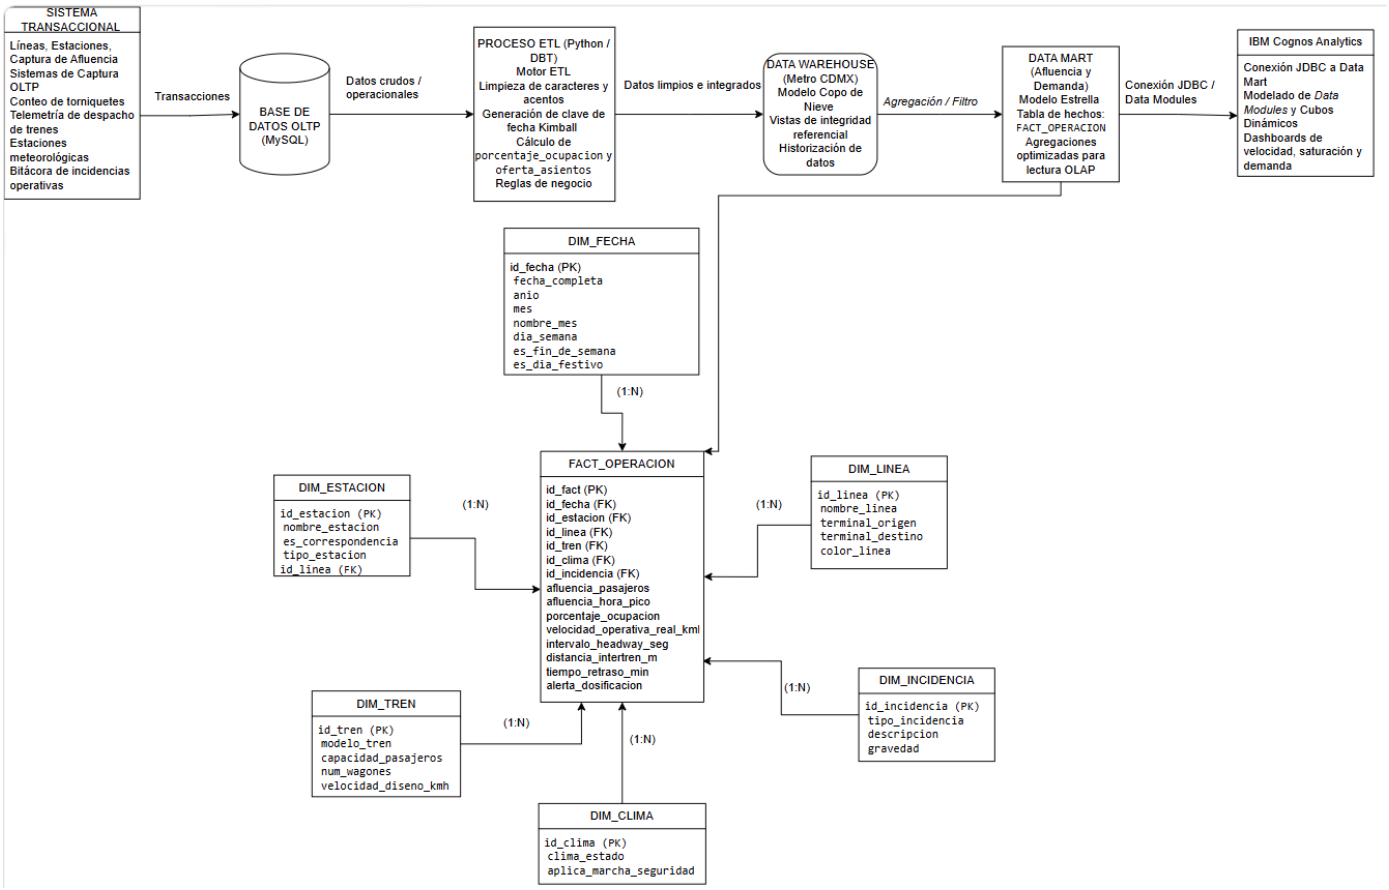
El proyecto consiste en la evolución de un sistema de información convencional hacia una arquitectura de analítica de datos e inteligencia de negocios de tres capas para el Sistema de Transporte Colectivo (STC) Metro de la Ciudad de México. El objetivo principal es transformar grandes volúmenes de datos operativos desestructurados en una plataforma analítica centralizada que permita medir la eficiencia del servicio, evaluar patrones de demanda y analizar cuellos de botella en la red. Para lograrlo, la arquitectura integra una capa de extracción y procesamiento masivo de datos mediante canalizaciones (*pipelines*) ETL desarrolladas en Python, un almacén de datos (*Data Warehouse*) modelado bajo un esquema en Copo de Nieve (*Snowflake Schema*) sobre MySQL Server, y una capa analítica de procesamiento de inteligencia de negocios (*Data Mart*) desplegada en la nube con IBM Cognos Analytics para la toma de decisiones basada en indicadores clave de desempeño (KPIs).

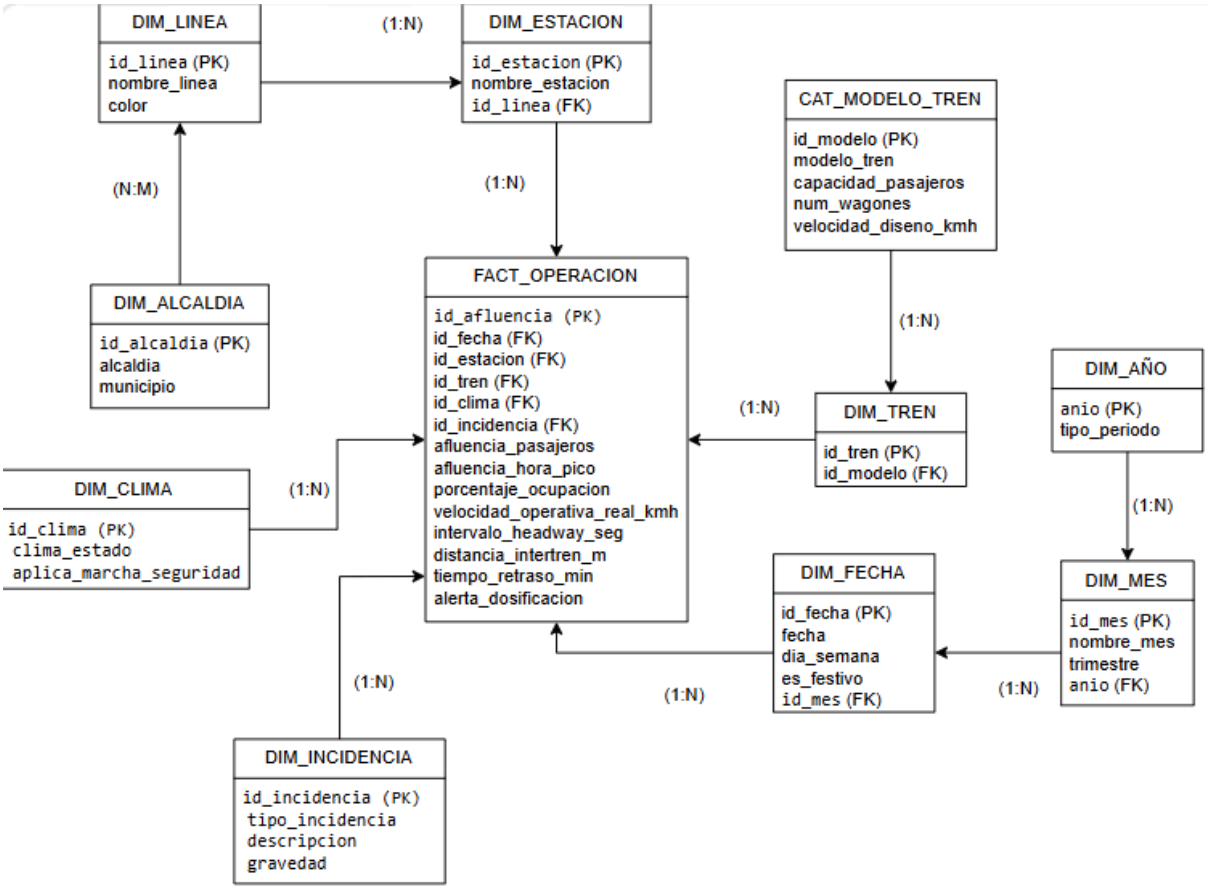
Definición y Caracterización de las Fuentes de Datos de Origen

Las fuentes de datos de origen (capa OLTP) están constituidas por los registros operativos y administrativos generados de manera continua por la operación del STC Metro. Estos conjuntos de datos provienen principalmente del repositorio de Datos Abiertos de la Ciudad de México, complementados conceptualmente por los registros de los Puestos Centrales de Control (PCC) y las bitácoras de mantenimiento de material rodante. La información recopilada abarca los registros de afluencia diaria de usuarios por estación, los reportes de averías e incidencias técnicas, los tiempos de recorrido de los trenes y las lecturas de condiciones meteorológicas por zona geográfica.

En su estado original, la información se presenta en formatos planos y desnormalizados, como archivos delimitados por comas (CSV) y hojas de cálculo de Excel. Estos archivos se caracterizan por una alta redundancia de texto, falta de integridad referencial y formatos heterogéneos en los campos de fecha y hora. La ingesta de datos se define bajo un esquema de procesamiento por lotes (*Batch Processing*), abarcando históricos con una volumetría de cientos de miles de registros. Este volumen requiere un proceso de limpieza, estandarización y transformación mediante Python para mapear los textos nativos hacia llaves primarias y foráneas dentro del modelo dimensional en MySQL.


CAT_LINEA
id_linea (PK)
nombre_linea
color_linea
terminal_origen
terminal_destino
(1:N)
CAT_ESTACION
id_estacion (PK)
nombre_estacion
id_linea (FK)
es_correspondencia
tipo_estacion
(1:N)
CAT_TORNIQUETE
id_torniquete (PK)
id_estacion (FK)
num_serie
estado_operativo
(1:N)
TRANS_AFLUENCIA_TORNIQUETE
id_transaccion (PK)
id_torniquete (FK)
fecha_hora
tipo_acceso
(1:N)
CAT_TREN
id_tren (PK)
modelo_tren
capacidad_pasajeros
num_wagones
velocidad_diseno_kmh
(1:N)
TRANS_DESPACHO_CONVOY
id_despacho (PK)
id_tren (FK)
id_linea (FK)
fecha_hora_salida
velocidad_operativa_kmh
intervalo_headway_seg
distancia_intertren_m
(1:N)
CAT_SENSOR_CLIMA
id_sensor (PK)
id_estacion (FK)
ubicacion_geografica
(1:N)
TRANS_REGISTRO_CLIMA
id_registro_clima (PK)
id_sensor (FK)
fecha_hora
temperatura_c
clima_estado
aplica_marcha_seguridad
(1:N)
TRANS_REGISTRO_INCIDENCIA
id_registro_incidencia (PK)
id_despacho (FK)
id_tipo_incidencia (FK)
fecha_hora_inicio
tiempo_retraso_min
(1:N)
CAT_TIPO_INCIDENCIA
id_tipo_incidencia (PK)
descripcion
gravedad_defecto

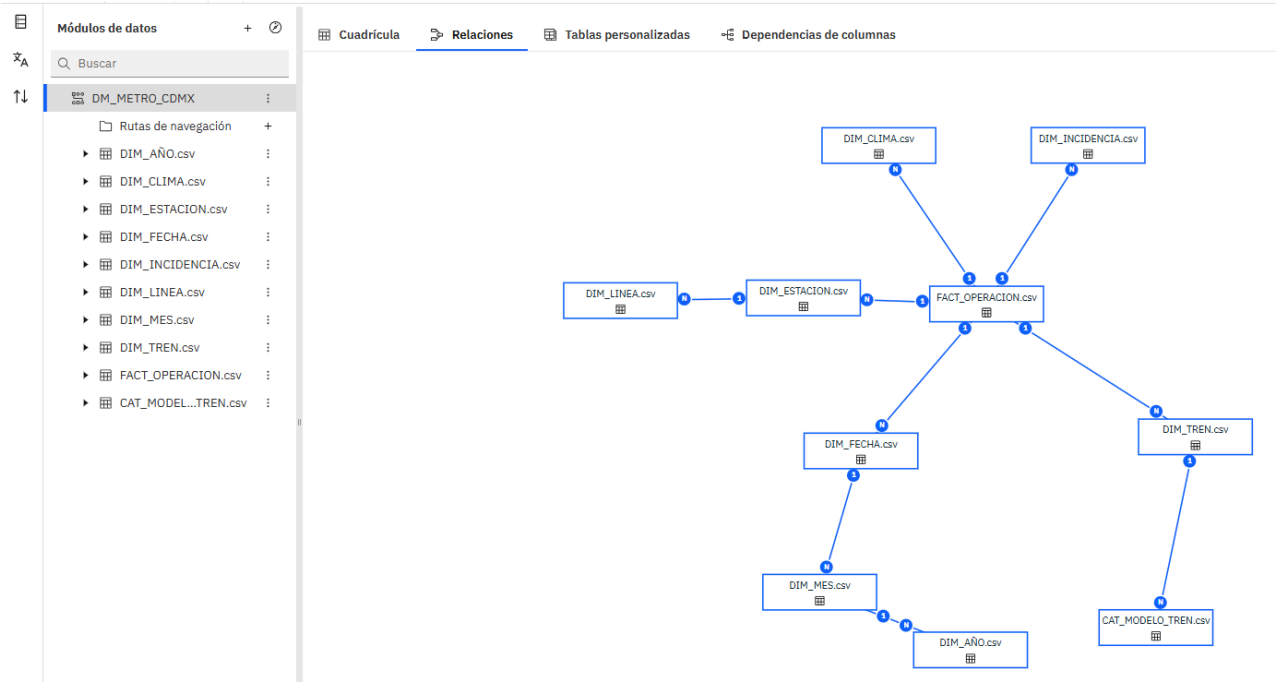

SISTEMA TRANSACCIONAL
Líneas, Estaciones, Captura de Afluencia
Sistemas de Captura OLTP
Conteo de torniquetes
Telemetría de despacho de trenes
Estaciones meteorológicas
Bitácora de incidencias operativas
Transacciones
BASE DE DATOS OLTP (MySQL)
Datos crudos / operacionales
PROCESO ETL (Python / DBT)
Motor ETL
Limpieza de caracteres y acentos
Generación de clave de fecha Kimball
Cálculo de porcentaje_ocupacion y oferta_asientos
Reglas de negocio
Datos limpios e integrados
DATA WAREHOUSE (Metro CDMX)
Modelo Copo de Nieve
Vistas de integridad referencial
Historización de datos
Agregación / Filtro
DATA MART (Afluencia y Demanda)
Modelo Estrella
Tabla de hechos: FACT_OPERACION
Agregaciones optimizadas para lectura OLAP
Conexión JDBC / Data Modules
IBM Cognos Analytics
Conexión JDBC a Data Mart
Modelado de Data Modules y Cubos Dinámicos
Dashboards de velocidad, saturación y demanda
DIM_FECHA
id_fecha (PK)
fecha_completa
anio
mes
nombre_mes
dia_semana
es_fin_de_semana
es_dia_festivo
(1:N)
FACT_OPERACION
id_fact (PK)
id_fecha (FK)
id_estacion (FK)
id_linea (FK)
id_tren (FK)
id_clima (FK)
id_incidencia (FK)
afluencia_pasajeros
afluencia_hora_pico
porcentaje_ocupacion
velocidad_operativa_real_kml
intervalo_headway_seg
distancia_intertren_m
tiempo_retraso_min
alerta_dosificacion
DIM_ESTACION
id_estacion (PK)
nombre_estacion
es_correspondencia
tipo_estacion
id_linea (FK)
(1:N)
DIM_LINEA
id_linea (PK)
nombre_linea
terminal_origen
terminal_destino
color_linea
(1:N)
DIM_INCIDENCIA
id_incidencia (PK)
tipo_incidencia
descripcion
gravedad
(1:N)
DIM_TREN
id_tren (PK)
modelo_tren
capacidad_pasajeros
num_wagones
velocidad_diseno_kmh
(1:N)
DIM_CLIMA
id_clima (PK)
clima_estado
aplica_marcha_seguridad
(1:N)



Nota de implementación: Atendiendo a la propuesta académica del titular de la asignatura, la capa de modelado semántico y la construcción de los cuadros de mando principales se desplegaron en la plataforma IBM Cognos Analytics (DM_METRO_CDMX y DASHBOARD_METRO_CDMX). De manera complementaria, el Data Warehouse local montado en MySQL Server mantiene compatibilidad nativa mediante conectores ODBC para su consumo en Power BI, garantizando interoperabilidad y flexibilidad tecnológica.

6. Modelado Semántico en IBM Cognos Analytics

En la plataforma IBM Cognos Analytics se configuró el Módulo de Datos denominado DM_METRO_CDMX. Dentro de este entorno se establecieron las uniones y cardinalidades del esquema Copo de Nieve, vinculando la tabla central FACT_OPERACION en relación de muchos a uno (N:1) con las dimensiones principales (DIM_ESTACION, DIM_TREN, DIM_CLIMA, DIM_INCIDENCIA y DIM_FECHA). Asimismo, se modelaron las relaciones secundarias de segundo nivel para DIM_LINEA, CAT_MODELO_TREN, DIM_MES y DIM_AÑO, garantizando la navegación multidimensional.



7. Explotación y Visualización (Dashboard Operativo)

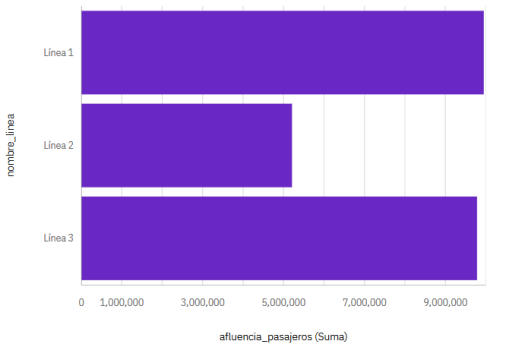
Como producto final de la capa de visualización se diseñó el panel de control interactivo `DASHBOARD_METRO_CDMX`. El cuadro de mando incorpora tarjetas resumen con los Indicadores Clave de Desempeño (KPIs) de afluencia acumulada y el tiempo promedio de retraso en minutos. Adicionalmente, incluye un gráfico de barras comparativo que distribuye el flujo de usuarios a través de las distintas líneas de la red (`nombre_linea` vs. `afluencia_pasajeros`), permitiendo la identificación oportuna de cuellos de botella operativos.

afluencia_pasajeros

24.9 M

afluencia_pasajeros

afluencia_pasajeros por nombre_linea



tiempo_retraso_min

8.57

tiempo_retraso_min